Titre et Synthèse Exécutive

MedBot: Système de Classification d'Intention pour la Santé

MedBot: Système de Classification d'Intention pour la Santé

- Application d'un Réseau Neuronal Dense (PyTorch) sur Features TF-IDF.
- Automatisation de l'assistance de premier niveau garantissant une classification rapide et fiable

Auteur: Antonine Pelicier // Steve Calixte

Github: https://github.com/Poincare008

LinkedIn: https://www.linkedin.com/in/antonine-pelicier // Clik

Rôle: Développeur AI and Data scientist

Enjeu Métier et Proposition de Valeur

Efficacité Opérationnelle et Fiabilité

- **Problématique**: Désengorgement des services de santé dû au volume élevé de requêtes routinières.
- Solution Ciblée: Implémenter un système de NLU (Natural Language Understanding) pour la catégorisation en temps réel.
- **Proposition de Valeur :** Réponse instantanée et fiabilité de la classification des intentions.
- **KPI Clé :** Précision de Classification d'Intention >60% | Taux d'automatisation des réponses initiales.

Architecture Modulaire du Pipeline

Architecture Modulaire du Pipeline Data-Centrique

Architecture Modulaire du Pipeline Data-Centrique

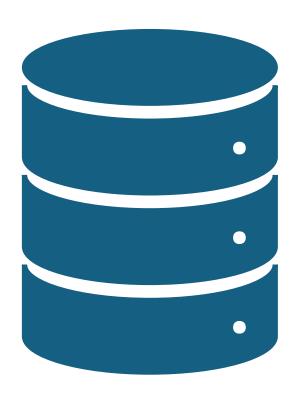
- Diagramme de Flux : INPUT (Texte) → NLP Pipeline → Modèle PyTorch
 →OUTPUT (Réponse).
- Étapes Clés du Pré-traitement :
- 1. Acquisition de données structurées (healthcare_intents.json).
- 2. Tokenization et Suppression des Stop Words.
- 3. Normalisation par **Lemmatisation (NLTK)** pour minimiser la variance lexicale.

Pré-traitement et Feature Engineering (NLP)

Représentation Sémantique par TF-IDF

Représentation Sémantique par TF-IDF

- **Méthode**: Utilisation du **TF-IDF** (Term Frequency-Inverse Document Frequency) pour la vectorisation
- Raisonnement : Crée une représentation vectorielle discriminante en pondérant l'importance des termes rares du vocabulaire.
- Sortie : Matrice d'entrée X appartient a l'emsemble R pour le réseau.
- Artefact: L'instance du vectoriseur est sauvegardée dans le fichier .pkl (meta_tfidf.pkl).



Architecture du **ChatbotModel** (PyTorch)

Architecture du Modèle de Deep Learning

Architecture du ChatbotModel (PyTorch)

Cadre: MLP (Multi-Layer Perceptron) implémenté via nn. Module

Topologie:

Réduction
progressive des
couches:

• Input \rightarrow 512 \rightarrow 256 \rightarrow 128 \rightarrow 64 \rightarrow Output

Optimisation & Régularisation :

- Batch Normalization pour la stabilité et la vitesse.
- **Dropout** (0.4) pour prévenir le surapprentissage.



Stratégie d'Entraînement et Validation

Stratégie d'Entraînement et de Validation Rigoureuse

Stratégie d'Entraînement et Validation Rigoureuse

- Hyperparamètres Clés :
 - **Loss**: nn.CrossEntropyLoss.
 - Optimiseur : optim.Adam.
 - Gestion du Learning Rate : StepLR Scheduler.
- Validation : Partitionnement Train/Test (80/20) avec Stratification pour garantir une distribution équilibrée des classes.
- Référence Code : Logique d'entraînement dans le fichier Chatbot.ipynb

Performances et Métriques

Résultats et Métriques de Performance (Test Set)

Résultats et Métriques de Performance (Test Set)

Convergence: Graphique de la Courbe de Perte

→ Convergence rapide et stable sur 50 époques.

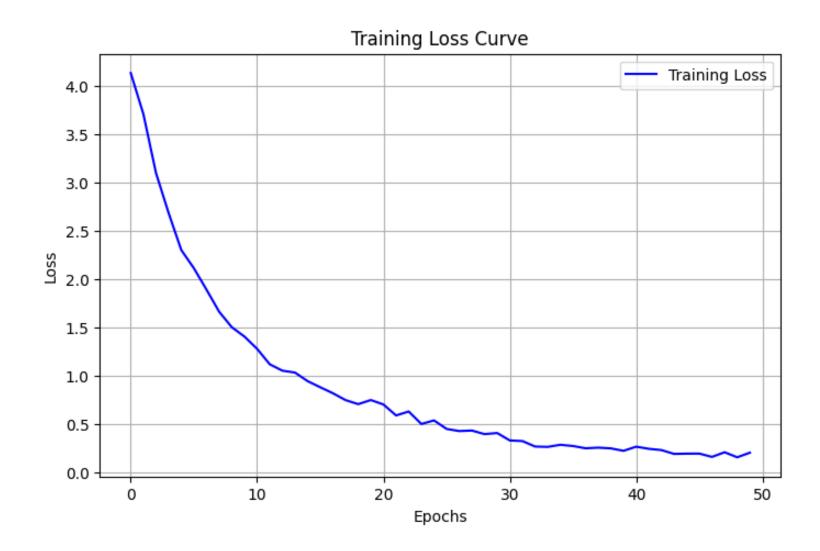
Précision Globale : Accuracy sur l'Ensemble de Test

Analyse Détaillée : Rapport de Classification (F1-Score, Précision, Rappel) élevé sur l'ensemble des intentions, validant la robustesse.

Artefact : Poids entraînés sauvegardés dans le fichier .pth (chat_model_tfidf.pth).



Graphique de la Courbe de Perte



Logique de Décision et Résilience

Résilience et Logique de Décision (MLOps)

Résilience et Logique de Décision (MLOps)

- **Mécanisme :** Probabilités calculées par **Softmax** → Classification basée sur la Confiance Maximale.
- Seuil de Confiance: Implémentation d'un Seuil de 0.65 pour garantir la fiabilité.
- Journalisation de l'Incertitude: Requêtes sous le seuil stockées dans uncertain_inputs.log pour la supervision humaine et le ré-entraînement (MLOps).

Déploiement et Expérience Utilisateur

Déploiement de l'Interface Utilisateur (UX)

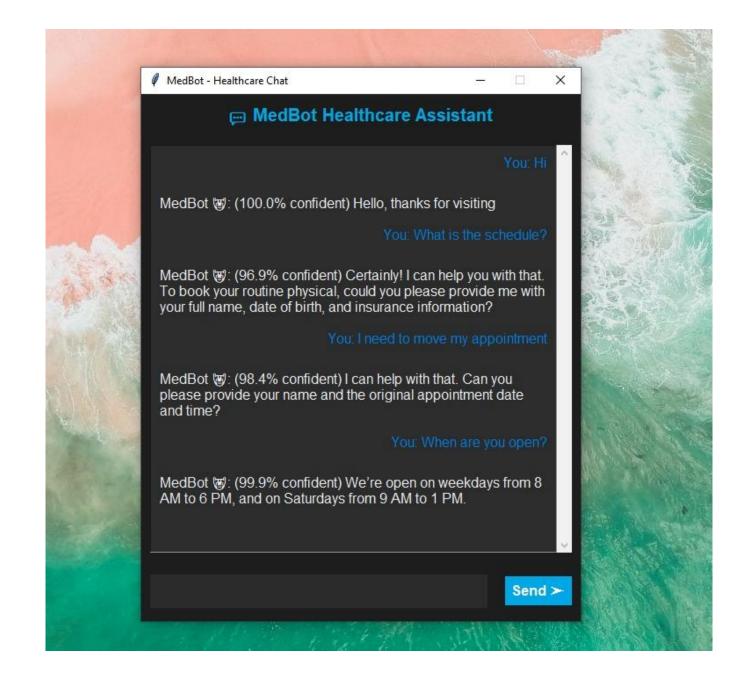
L'Interface Utilisateur (UX)

Interface: Application cliente ModernChatApp développée en Tkinter (stand-alone).

Performance
Asynchrone: Utilisation
du Threading Python
pour l'exécution nonbloquante de la
prédiction du modèle.

Avantage UX : Le GUI reste réactif (affichage "typing...") pendant que la prédiction s'exécute en arrière-plan.

L'Interface Utilisateur (UX)





Conclusion et Feuille de Route Stratégique

Conclusion et Feuille de Route Stratégique

- **Synthèse**: Validation du système de classification d'intention Deep Learning haute performance.
- Roadmap Technique: Migration vers des Word Embeddings (Word2Vec, FastText)
 pour une capture sémantique plus riche (remplacement de TF-IDF).
- Roadmap Produit : Déploiement en Micro-service (Flask/Streamlit) et intégration de la logique de *Tool-Use* (appel d'API pour actions concrètes).

Limite de notre ChatBot

- Dataset
- Limites dans le Traitement du Langage Naturel (NLP): C'est la limitation la plus significative, car elle est inhérente à la méthode TF-IDF.
- Limites du Modèle (Architecture MLP): Bien que le MLP soit efficace, il a des contraintes par rapport aux architectures séquence-à-séquence.
- Limites Opérationnelles et Évolutives

Possibilité d'amélioration

- Disponible dans au moins 3 langues(Créole/Français/Anglais)
- Amélioration du Traitement du Langage Naturel (NLP): Le point de blocage actuel est le TF-IDF (Bag-of-Words). La première amélioration est de remplacer cette technique par une méthode qui capture la sémantique et le contexte.
- **Migration** vers des **Word Embeddings** afin d'enrichir la représentation des données pour le modèle PyTorch.

Webographie

https://chatbotsmagazine.com/ contextual-chat-bots-withtensorflow-4391749d0077 2

https://youtu.be/a040VmmO-AY?si=9IJ82qXV6B5TRzzv

3

https://github.com/patrickloeber/pytorch-chatbot

4

https://youtu.be/RpWeNzfSUHw?si=KF1174rAolEus9nb



Thank you